

Checkpoint 1 - Grupo 08

Análisis Exploratorio

Análisis exploratorio:
460154 registros 20 columnas

RangeIndex: 460154 entries, 0 to 460153

Data columns (total 20 columns):

#	Column	Non-Null Count	Dtype
0	id	460154 non-null	object
1	start_date	460154 non-null	object
2	end_date	460154 non-null	object
3	created_on	460154 non-null	object
4	latitud	419740 non-null	float64
5	longitud	419740 non-null	float64
6	place_l2	460154 non-null	object
7	place_l3	437665 non-null	object
8	place_l4	139020 non-null	object
9	place_l5	2430 non-null	object
10	place_l6	0 non-null	float64
11	operation	460154 non-null	object
12	property_type	460154 non-null	object
13	property_rooms	368498 non-null	float64
14	property_bedrooms	344113 non-null	float64
15	property_surface_total	397813 non-null	float64
16	property_surface_covered	427916 non-null	float64
17	property_price	442153 non-null	float64
18	property_currency	441590 non-null	object
19	property_title	460154 non-null	object

Hipotesis:

L2 = Provincia (Capital Federal, GBA Zona Norte, GBA Zona Sur, Entre Ríos, Neuquen, etc)

L3 = Ciudad / Barrio (Nordelta, Tigre, Rosario, Pilar). Tambien ambiguo, pero filtrando por Capital Federal son los barrios de CABA

L4 = Localidad (Olivos, Nordelta, Jose C. Paz, etc). Un poco ambiguo, los resultados en L2 Capital Federal son Palermo Chico, Hollywood, Soho y Viejo

L5 = Barrio privado (BarrioPortezuelo, Barrio La Alameda, Barrio El Yacht, etc)

Nota: Todos se encuentran en Tigre, no es relevante para nosotros

L6 = Nada. Se descartará

Datos estadísticos:

index	latitud	longitud	Ambientes	Habitacion es	Superficie total	superficie cubierta	Precio
promedio	-34,2	-59,6	3,3	2,3	420,6	9605,0	306327,3
std	3,3	2,9	1,9	1,7	4026,4	3440367,0	4899613,1
min	-54,8	-103,2	1,0	-3,0	-1,0	-3,0	0,0
25,00 %	-34,6	-58,9	2,0	1,0	50,0	45,0	44900,0
50,00 %	-34,6	-58,5	3,0	2,0	90,0	78,0	98000,0
75,00 %	-34,4	-58,4	4,0	3,0	210,0	170,0	199000,0
max	42,6	-35,0	40,0	390,0	200000,0	2147483647,0	1500000000,0

Como primer punto, podemos observar como la latitud y la longitud se encuentran muy distribuidas respecto del promedio, con una desviación de aproximadamente tres grados en ambos casos. Esto nos indica luego de un primer vistazo que la información debe tener errores ya que tres grados en corresponden a un arco de trescientos kilómetros, comparable con la distancia de CABA a Rosario. Luego, las habitaciones, cuartos parecen ser correctas y con una distribución similar, pero con valores extraños para mínimo y máximo (390 habitaciones esta lejos de ser una casa).

Preprocesamiento de Datos

Detallar las tareas más importantes que realizaron sobre el dataset, les dejamos algunas preguntas cómo guía:

1. ¿Se eliminaron columnas (Nombre de la columna y motivo de eliminación)?
2. ¿Detectaron correlaciones interesantes (entre qué variables y qué coeficiente)?
3. ¿Generaron nuevos features?

4. ¿Encontraron valores atípicos? ¿Cuáles? ¿Qué técnicas utilizaron y qué decisiones tomaron?
5. ¿Qué columnas tenían datos faltantes?
¿En qué proporción? ¿Qué se hizo con estos registros?

Visualizaciones

Mostrar dos gráficos realizados: dispersión entre variables, histogramas, heatmaps, etc. que sean descriptivos del problema. Seleccionar aquellos que permitan entender cómo se distribuyen los datos, cómo se relacionan las variables etc. Comentar brevemente qué se está visualizando en cada caso y por qué los eligieron.

Clustering

Mencionar -si se analizó- la tendencia al clustering y la cantidad apropiada de grupos que se deben formar. Mostrar cómo llegaron a esa conclusión..

Estado de Avance

1. Análisis Exploratorio y Preprocesamiento de Datos

Porcentaje de Avance: 15%/100%

Tareas en curso: detallar en qué puntos están trabajando.

Tareas planificadas: detallar con qué tareas tienen pensado continuar.

Impedimentos: mencionar temas que sean bloqueantes para ustedes.

- a) Exploración Inicial: detallar tareas pendientes si las hubiera.
- b) Visualización de los datos: detallar tareas pendientes si las hubiera.
- c) Datos Faltantes: detallar tareas pendientes si las hubiera.
- d) Valores atípicos: detallar tareas pendientes si las hubiera.

e) Opcional: si están trabajando en alguna tarea adicional de preprocesamiento detallar aquí

2. Agrupamiento

Porcentaje de Avance: 00%/100%

Tareas en curso: detallar en qué puntos están trabajando.

Tareas planificadas: detallar con qué tareas tienen pensado continuar.

Impedimentos: mencionar temas que sean bloqueantes para ustedes.

Nota: si avanzaron con los puntos 3 y 4 detallar aquí también.

Tiempo dedicado

Indicar brevemente en qué tarea trabajó cada integrante del equipo durante estas semanas. Si trabajaron en las mismas tareas lo detallan en cada caso (como en el ejemplo el armado de reporte). Deben indicar el promedio de horas semanales que dedicaron al trabajo práctico.

Integrante	Tarea	Prom. Hs Semana
Testa, Santiago Tomas	Analisis exploratorio	5hs
Ramirez, Jose Israel	Analisis exploratorio	5hs
Pratto, Federico Nicolas		
Torres, Santiago/Danny		